

# 实习实践报告：短文本对话

---



网龙网络公司  
NETDRAGON WEBSOFT INC.

报告人：林连升

校内导师：叶东毅 教授

企业导师：关胤

实习单位：福建天晴在线互动科技有限公司

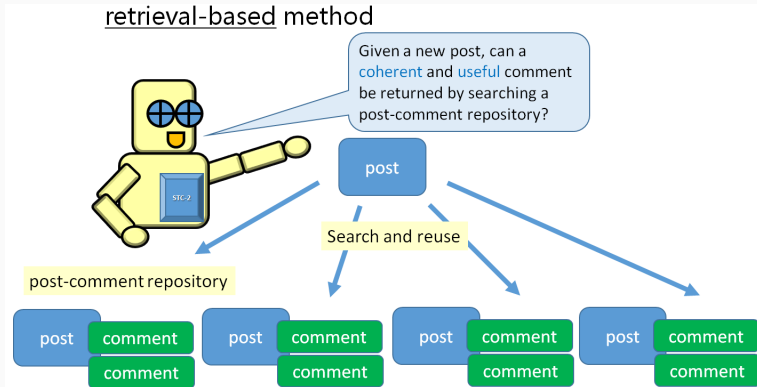


Figure 1: 基于检索的方法

评估检索出的评论主要遵循以下四个准则:

1. Fluent
2. Coherent: logically and topically relevant
3. Self-sufficient
4. Substantial

If either (1) or (2) is untrue, the retrieved comment should be labeled "L0"; if either (3) or (4) is untrue, the label should be "L1"; otherwise, the label is "L2".

| Post     | 意大利禁区里老是八个人...太夸张了吧<br>There are always 8 Italian players in their own restricted area...Unbelievable! | Related Criteria    | Labels |
|----------|--|---------------------|--------|
| Comment1 | 我是意大利队的球迷，等待比赛开始。<br>I am a big fan of the Italy team, waiting for the football match to start         | (2) Coherent        | L0     |
| Comment2 | 意大利的食物太美味了<br>Italian food is absolutely delicious.  | (2) Coherent        | L0     |
| Comment3 | 太夸张了吧!<br>Unbelievable!  | (4) Substantial     | L1     |
| Comment4 | 哈哈哈仍然是0: 0。还没看到进球。<br>Haha, it is still 0:0, no goal so far.   | (3) Self-sufficient | L1     |
| Comment5 | 这正是意大利式防守足球。<br>This is exactly the Italian defending style football game                              | ——                  | L2     |

Figure 2: 一条微博以及人工标注的五条候选评论




Figure 3: System Architecture

- 繁简转换
- 全角转半角
- 分词 (pynlpir, PKU 标准)
- token 替换 (<\_NUM>, <\_TIME>, <\_URL>)
- 过滤无意义的词和特殊符号

|                        |   |
|------------------------|---|
| Short Text ID          | test-post-10440   |
| Raw Text               | 去到美國，还是吃中餐！宮保雞丁家的感覺～<br>Go to the USA, still eat Chinese food, Kung Pao Chicken, feeling like at home |
| Without T-S Conversion | 去 到 美 國 ， 还 是 吃 中 餐 ！ 宮 保 雞 丁 家 的 感 覺 ~   |
| With T-S Conversion    | 去 到 美 国 ， 还 是 吃 中 餐 ！ 宮 保 鸡 丁 家 的 感 觉 ~   |
| Clean Result           | 去 到 美 国 还 是 吃 中 餐 宮 保 鸡 丁 家 的 感 觉   |

|                           |   |
|---------------------------|---|
| Short Text ID             | test-post-10640   |
| Raw Text                  | 汶川大地震9周年： 29个让人泪流满面的瞬间。<br>9th Anniversary of Wenchuan Earthquake: 29 moments making people tearful |
| Without token replacement | 汶 川 大 地 震 9 周 年 ： 29 个 让 人 泪 流 满 面 的 瞬 间 。  |
| With token replacement    | 汶 川 大 地 震 <_NUM> 周 年 ： <_NUM> 个 让 人 泪 流 满 面 的 瞬 间 。   |
| Clean Result              | 汶 川 大 地 震 <_NUM> 周 年 <_NUM> 个 让 人 泪 流 满 面 的 瞬 间   |

- TF-IDF
- LSA (Latent Semantic Analysis)
- LDA (Latent Dirichlet Allocation)
- Word2Vec (skip-gram)
- **LSTM-Sen2Vec**

我们将每条微博和它的所有评论合并成一个文档，然后对这些文档训练 LSA 和 LDA 模型。其他模型是以句子作为输入。



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (3)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t * \tanh(C_t) \quad (6)$$

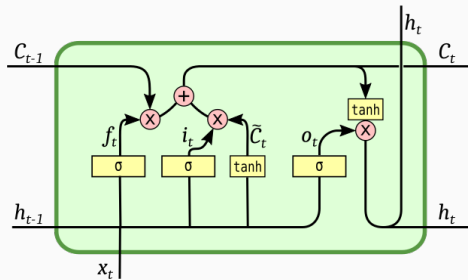




Figure 4: LSTM 单元

Mikolov, Toma's. Statistical Language Models Based on Neural Networks. Ph.D. thesis, Brno University of Technology.(2012)

Zaremba, Wojciech, I. Sutskever, and O. Vinyals. Recurrent Neural Network Regularization. Eprint Arxiv (2014).



**Figure 5:** Unidirectional weight distribution



**Figure 6:** bidirectional weight distribution




Figure 7: The Unidirectional LSTM




Figure 8: The Traditional Bidirectional LSTM

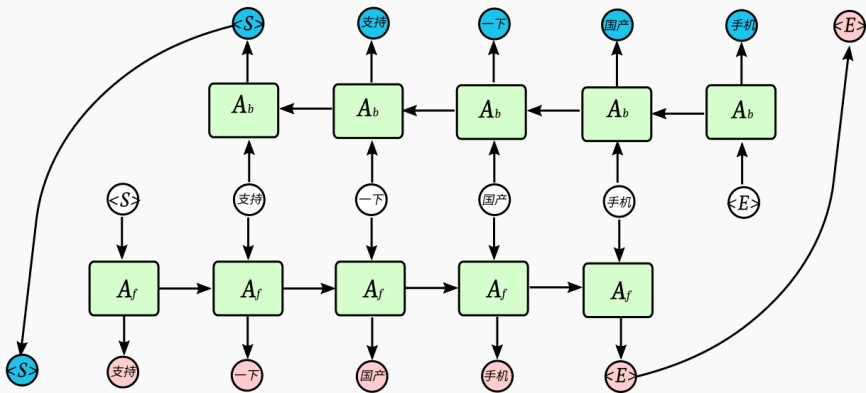


Figure 9: The Modified Bidirectional LSTM

- 相似的微博

$$Score_{q,p}^1(q, p) = Sim_{LDA}(q, p) * Sim_{W2V}(q, p) * Sim_{LSTM}(q, p) \quad (7)$$

$$Score_{q,p}^2(q, p) = Sim_{LSA}(q, p) * Sim_{W2V}(q, p) * Sim_{LSTM}(q, p) \quad (8)$$

- 候选评论

$$Score_{q,c}^1(q, c) = Sim_{LSA}(q, c) * Sim_{W2V}(q, c) \quad (9)$$

$$Score_{q,c}^2(q, c) = Sim_{LDA}(q, c) * Sim_{W2V}(q, c) \quad (10)$$

- TextRank (Words as vertices)
- Pattern-IDF
- Pattern-IDF + TextRank (Sentences as vertices)

设  $G = (V; E)$  为一个由点集  $V$  和边集  $E$  构成的无向图, 其中  $E$  是  $V \times V$  的子集. 对于一个给定的点  $V_i$ , 设  $link(V_i)$  为与其相连的点的集合. 则一个点  $V_i$  的分数定义如下:

$$WS(V_i) = (1 - d) + d * \sum_{j \in link(V_i)} w_{ij} * WS(V_j) \quad (11)$$

其中  $d$  是一个 damping factor<sup>1</sup>, 通常设为 0.85.

---

<sup>1</sup>Brin, Sergey, and L. Page. The anatomy of a large-scale hypertextual Web search engine. International Conference on World Wide Web Elsevier Science Publishers B. V. 1998:107-117.

- Vertices: 候选评论中的每个词
- Edges: 共现关系
- Weighted by: word2vec 相似度和共现次数



对于  $N$  个候选评论,  $k$  个词语, 我们构建一个  $k \times k$  的矩阵  $M$ . 其中  $M_{ij} = cnt * sim(D_i, D_j)$ . 然后我们迭代计算

$$R(t+1) = \begin{bmatrix} (1-d)/k \\ (1-d)/k \\ \dots\dots\dots \\ (1-d)/k \end{bmatrix} + d \begin{bmatrix} M_{11} & M_{12} & M_{13} & \dots & M_{1k} \\ M_{21} & M_{22} & M_{23} & \dots & M_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ M_{k1} & M_{k2} & M_{k3} & \dots & M_{kk} \end{bmatrix} R(t)$$

Stop when  $|R(t+1) - R(t)| < \epsilon$ ,  $\epsilon = 10^{-7}$ .

这里,  $cnt$  表示  $D_i$  和  $D_j$  在一个句子中共现的次数.

既然我们得到候选评论中每个词  $D_i$  的分数  $R(D_i)$ , 那么每个候选评论  $c$  的分数可以按下列式子计算:

$$Rank_{TextRank}(c) = \frac{\sum_{D_i \in c} R(D_i)}{len(c)} \quad (12)$$

这里,  $len(c)$  表示候选评论中词语的个数.

对于微博中的一个词语  $D_j$  和相应评论中的一个词语  $D_i$ , 我们定义  $(D_j, D_i)$  为一个 pattern.

受到 TF-IDF 的启发, 我们定义 Pattern-IDF 为:

$$PI(D_i|D_j) = 1/\log_2 \frac{count_c(D_i) * count_p(D_j)}{count_{pair}(D_i, D_j)} \quad (13)$$

这里,  $count_c$  表示词语出现在评论中的次数,  $count_p$  表示词语出现在微博中的次数,  $count_{pair}$  表示  $(D_j, D_i)$  的个数.  $count_{pair}(D_i, D_j)$  小于 3 的 PI 将被移除.

Let  $X = \frac{\text{count}_c(D_i) * \text{count}_p(D_j)}{\text{count}_{\text{pair}}(D_i, D_j)}$ , then  $X \in [1, \infty)$ .




Figure 10:  $\log(X)$




Figure 11:  $1/\log(x)$

Table 1: The example of Pattern-IDF

| Major Word          | Minor Word           | PI       |
|---------------------|----------------------|----------|
| 中国移动 (China Mobile) | 接通 (connect)         | 0.071725 |
| 中国移动                | cmcc                 | 0.067261 |
| 中国移动                | 资费 (charges)         | 0.062408 |
| 中国移动                | 营业厅 (business hall ) | 0.059949 |
| 中国移动                | 漫游 (roaming)         | 0.059234 |
| ...                 | ...                  | ...      |
| 中国移动                | 我 (me)               | 0.028889 |
| 中国移动                | 是 (be)               | 0.027642 |
| 中国移动                | 的 (of)               | 0.026346 |

Table 2: The entropy of Pattern-IDF for each Major Word

| Major Word             | H         |
|------------------------|-----------|
| 眼病 (eye disease)       | 0.889971  |
| 丰收年 (harvest year)     | 0.988191  |
| 血浆 (plasma)            | 1.033668  |
| 脊椎动物 (vertebrate)      | 1.083438  |
| 水粉画 (gouache painting) | 1.180993  |
| ...                    | ...       |
| 现在 (now)               | 9.767768  |
| 什么 (what)              | 10.219045 |
| 是 (be)                 | 10.934950 |

$$PI_{norm}(D_i|D_j) = \frac{PI(D_i|D_j)}{\sum_{i=1}^n PI(D_i|D_j)} \quad (14)$$

$$H(D_j) = - \sum_{i=1}^n PI_{norm}(D_i|D_j) \log_2 PI_{norm}(D_i|D_j) \quad (15)$$

For each comment  $c$  in candidates, given a query (new post)  $q$ , we calculate the score by  $PI$  as follow:

$$Score_{PI}(q, c) = \frac{\sum_{D_j \in q} \sum_{D_i \in c} PI(D_i | D_j)}{len(c) * len(q)} \quad (16)$$

Then we define rank score as follow:

$$Rank_{PI} = (1 + \frac{Score_{PI}(q, c)}{\max Score_{PI}(q, c)}) * Sim_{W2V}(q, c) * Sim_{LSA}(q, c) \quad (17)$$

In this method, We add each comment sentence in candidates as a vertex in the graph and use sentence Word2Vec similarity as edges between vertices in the graph.

For  $N$  candidates, we construct  $N \times N$  matrix  $M$ .

$$M_{ij} = Sim_{w2v}(candidate_i, candidate_j).$$

At time  $t = 0$ , We initiate a  $N$ -dimension vector  $P$ , here  $N$  is the number of comment candidates. And each entry of  $P$  is defined as the score of Pattern-IDF between the query (new post)  $q$  and corresponding comment  $c_i$  in candidates:

$$P_i = Score_{PI}(q, c_i) \tag{18}$$

Then we compute iteratively

$$R(t+1) = \begin{bmatrix} (1-d)/N \\ (1-d)/N \\ \dots\dots\dots \\ (1-d)/N \end{bmatrix} + d \begin{bmatrix} M_{11} & M_{12} & M_{13} & \dots & M_{1N} \\ M_{21} & M_{22} & M_{23} & \dots & M_{2N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ M_{N1} & M_{N2} & M_{N3} & \dots & M_{NN} \end{bmatrix} R(t)$$

Stop when  $|R(t+1) - R(t)| < \epsilon$ ,  $\epsilon = 10^{-7}$

Finally, we get the score  $P_i$  for each comment in candidates.



- Nders-C-R5: LDA + Word2Vec + LSTM-Sen2Vec
- Nders-C-R4: LSA + Word2Vec + LSTM-Sen2Vec
- Nders-C-R3: R4 + TextRank (Words as vertices)
- Nders-C-R2: R4 + Pattern-IDF
- Nders-C-R1: R4 + Pattern-IDF + TextRank (Sentences as vertices)

Table 3: The official results

| Run        | Mean nG@1          | Mean P+            | Mean nERR@10       |
|------------|--------------------|--------------------|--------------------|
| Team 1     | 0.5867             | 0.6670             | 0.7095             |
| Team 2     | 0.5080             | 0.6080             | 0.6492             |
| Team 3     | 0.4980             | 0.5818             | 0.6105             |
| Nders-C-R1 | 0.4593             | 0.5394             | 0.5805             |
| Nders-C-R2 | 0.4743             | <b>0.5497(5th)</b> | <b>0.5882(5th)</b> |
| Nders-C-R3 | 0.4647             | 0.5317             | 0.5768             |
| Nders-C-R4 | <b>0.4780(4th)</b> | 0.5338             | 0.5809             |
| Nders-C-R5 | 0.4550             | 0.5495             | 0.5868             |
| R2 vs. R4  | ↓0.77%             | ↑2.98%             | ↑1.26%             |

Questions?